

Захар Зайцев

Data Scientist / ML Engineer

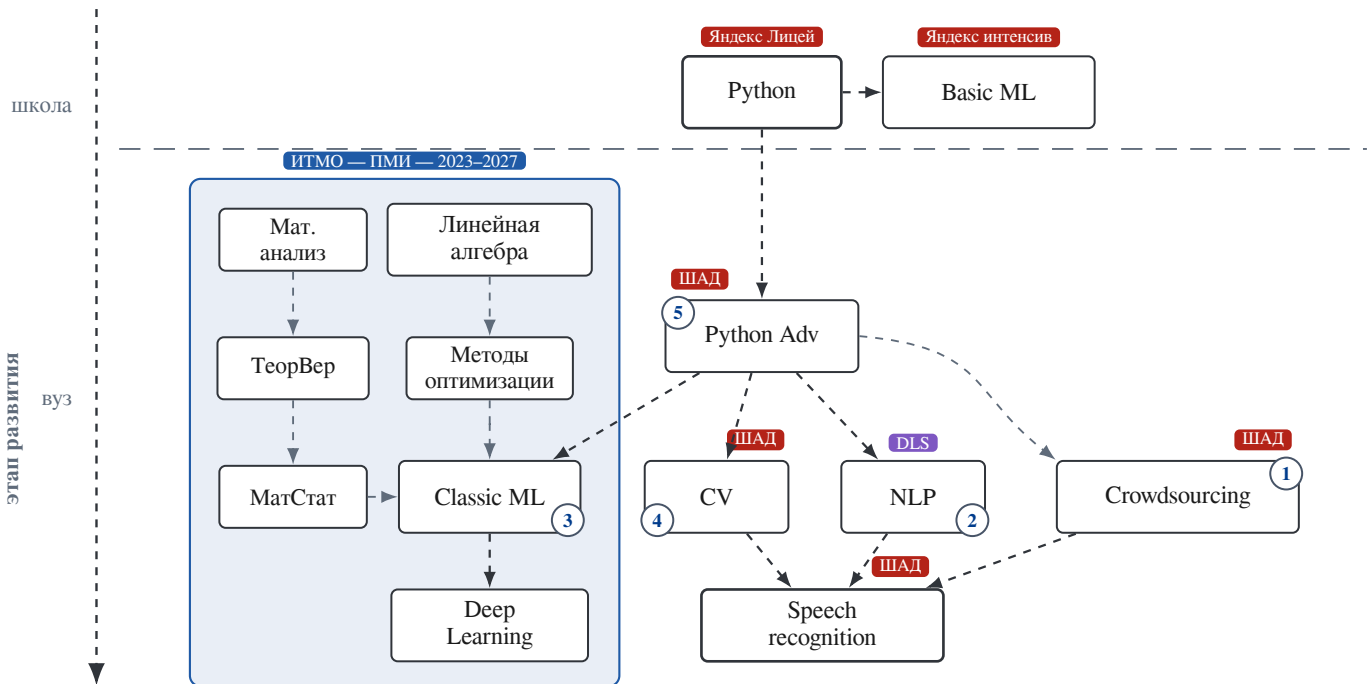
📍 Санкт-Петербург, Россия | ✉ zaitsev.zahar2016@yandex.ru | 🌐 [GrandZah](#) | 📱 [@terenazah](#)

ОБО МНЕ

Я учусь в ИТМО на направлении «Прикладная математика и информатика» и развиваюсь в сторону Data Science / ML Engineering. Работаю с ML-задачами полного цикла: от анализа и подготовки данных до обучения, оценки и улучшения моделей. Основные интересы — CV, NLP, Speech Recognition, классический ML и анализ данных. Сильная сторона — аккуратная работа с данными, проверка гипотез и доведение проекта до понятного и воспроизводимого результата.

Инструменты: Git, Linux, SQL, Docker. **Языки:** русский, английский — **B2 (Upper-Intermediate)**.

КАРТА РАЗВИТИЯ И СПЕЦИАЛИЗАЦИИ



КЛЮЧЕВЫЕ ПРОЕКТЫ

1. Активное обучение. Классификация спутниковых снимков

[Slides](#) [Crowdsourcing / CV](#) [5](#)

Team Lead проекта по классификации спутниковых снимков на наличие хвойных деревьев. Организовал работу команды из 5 человек, распределил роли и выстроил пайплайн от разметки до итоговой модели. Для разметки использовали **Яндекс Задачи**; предложил повысить яркость затемнённых изображений для разметчиков, и это решение отметили организаторы. Работал с **200 размеченными** и **33 000 неразмеченными** изображениями, итоговая **accuracy** превысила **80 %**.

2. Нормализация чисел в транскрибациях звонков

[Code](#) [NLP](#) [1](#)

Разработал rule-based решение для нормализации порядковых и количественных числительных в транскрибациях звонков. Использовал `rapidfuzz` и `ru morphology3`; основная сложность была в том, чтобы добавлять новые эвристики, не ломая качество на уже покрытых случаях. На наборе из **500 train / 500 test** достиг **accuracy = 0.964**.

3. Скоринг «топовости» карточки товара (ВкусВилл)

[Code](#) [E-commerce / Classic ML / NLP](#) [1](#)

Самостоятельно придумал и реализовал ML-проект по предсказанию, попадёт ли товар в топ-15% по рейтингу. Сам спарсил данные, подготовил выборку и построил end-to-end пайплайн обучения и оценки моделей в задаче с дисбалансом классов. Лучший результат показал **CatBoost: F1(test)=0.50** против **0.16** у случайного бейзлайна.

4. Deep Learning & Computer Vision (курс ШАД)

[CV / Deep Learning](#) [1](#)

В рамках CV-курса ШАД решал задачу классификации редких дорожных знаков на датасете **RTSD** с помощью генерации синтетических данных. Работал над архитектурой модели и подходом, который улучшал качество именно на редких классах, отсутствующих в обучающей выборке. Итоговая модель улучшила baseline: **accuracy** выросла с **0.6077** до **0.7717**, а **rare recall** — с **0.0000** до **0.4954** при **freq recall = 0.9000**.

5. OpenTransportMap — обработка транспортных геоданных

[Code](#) [Python Dev / Geo](#) [1](#)

Реализовал программу, которая по открытым данным массово генерирует транспортные карты для остановок города. Сделал весь пайплайн целиком: получение данных по API, парсинг, собственные структуры хранения, отрисовку карты и настройку её стиля. Основная сложность была в работе с шумными геоданными и нестрогой open-source разметкой маршрутов, поэтому пришлось закладывать реальные ошибки разметчиков в логику парсера.