

Захар Зайцев

Data Scientist / ML Engineer

📍 Санкт-Петербург, Россия | ✉ zaitsev.zahar2016@yandex.ru | 🌐 GrandZah | 🐦 @terenazah

ОБО МНЕ

Data Scientist / ML Engineer с академическим бэкграундом (ИТМО) и 5 годами опыта программирования на Python. Сильная сторона - разбираюсь в данных (артефакты, лики), строю бейзлайн и постепенно улучшаю модели через эксперименты. Интересны задачи анализа данных и проекты в области ML/CV/NLP.

КЛЮЧЕВЫЕ ПРОЕКТЫ

Скоринг «топовости» карточки товара (ВкусВилл)

[Code](#)

E-commerce / Classic ML / NLP 👤 1

Python, pandas, sklearn, CatBoost, TF-IDF, bootstrap

- Построил end-to-end пайплайн: парсинг и очистка данных, контроль качества и утечек.
- Цель: предсказать попадание товара в **топ-15%** по рейтингу; метрика - **F1** при пороге, подобранном под top-15%.
- Табличный baseline на CatBoost: F1(test): 0.50 (против: 0.16 у случайного).
- Добавил NLP-признаки: **TF-IDF** по тексту; получил устойчивый текстовый бейзлайн (F1 bootstrap mean: 0.45).
- Тестировал и другие подходы но они прироста не дали (ruBERT (mean-pooling)).

Deep Learning & Computer Vision (курс ШАД)

Компьютерное зрение 👤 1

NumPy, PyTorch, Lightning, backbones

- Прошёл все уровни абстракции: от реализации слоёв, лоссов и оптимизаторов в NumPy до полноценных пайплайнов обучения на PyTorch и Lightning.
- Решенные задачи: **Классификация птиц**: ассурасу около 0.876; **Редкие дорожные знаки** (RTSD с самостоятельной синтетикой): ассурасу: 0.768, rare_recall: 0.4914, freq_recall: 0.8967. **Сегментация** (COCO, LVIS): IoU@3 порядка 0.80 за счёт аккуратных аугментаций и (BCE+DiceLoss).

OpenTransportMap — обработка транспортных геоданных

[Code](#)

Python Dev / Geo 👤 1

Python, GeoPandas, OSM

- Построил пайплайн от сырых OSM-данных до подготовленных данных для построения транспортных карт.
- Обработывал маршруты и остановки с использованием GeoPandas, работал со сложной структурой геоданных.

Другие проекты

CV / Data analysis / Crowdsourcing 👤 4/5/5

PyTorch, моделирование

- **Классификация номеров домов**: Постепенное улучшение моделей и данных. Асс=0.94, F1=0.93. [Code](#)
- **Анализ бизнес-климата (DANO)**: Анализ временных рядов. Подготовленный датасет от ЦБ. Формирование и обоснование гипотез. Использование статистических тестов. [Presentation](#)
- **Классификация спутниковых снимков (ШАД)**: TeamLead: Управление командой в задаче с полным пайплайном - от преобразования и разметки за счет Crowdsourcing до итоговых моделей для прода. [Presentation](#)

ТЕХНИЧЕСКИЕ НАВЫКИ

- **ML**: линейные модели, деревья, бустинги; дисбаланс классов, кросс-валидация, подбор гиперпараметров.
- **DL/CV/NLP**: PyTorch, Lightning; классификация, детекция, сегментация (CNN-based); TF-IDF, BERT
- **Python/Data**: numpy, pandas, GeoPandas, polars, Optuna
- **Math**: теория вероятностей, математическая статистика, линейная алгебра, методы оптимизации.
- **Tools**: Git, Linux, SQL, Docker
- **Languages**: Русский, Английский — B2/C1.

ОБРАЗОВАНИЕ

Университет ИТМО

Санкт-Петербург

Бакалавр, Прикладная математика и информатика (ПМИ)

2023 – 2027

- Профильные курсы: теория вероятностей, математическая статистика, методы оптимизации, классический ML

Курс по Computer Vision (программа ШАД)

Online

PyTorch, архитектуры CNN, классификация, детекция, сегментация, трекинг (оценка: Отлично)

2025

Курс по сбору и разметке данных для машинного обучения (программа ШАД)

Online

Сбор данных, разметка, контроль качества, организация пайплайна датасета (оценка: Отлично)

2025